Pandas кітапханасы арқылы CSV файлдарымен жұмыс істеу

Орындаған: Орынбеков Губайдулла | **Тобы:** Инф-23-1 | **Пән:** Деректерді интеллектуалды талдау

1. Менің CSV файлым туралы жалпы мәлімет (students_data.csv)

Бұл блокнотта **«students_data.csv»** деректер жиынтығы (датасеті) қолданылды. Файлда университеттің 5 факультетінде (**Ақпараттық технологиялар, Экономика және бизнес, Инженерия, Педагогика, Заң факультеті**) және 8 мамандығында оқитын студенттердің академиялық үлгерімі жинақталған. Деректер жиынтығы **600 жолдан** және **12 бағаннан** тұрады:

№	Баған атауы	Мағынасы мен сипаттамасы	Деректер типі	Мәндер мысалы
1	Студент_ID	Студенттің реттік нөмірі (бірегей коды)	int64 (бүтін сан)	1, 2, 3 ... 600
2	Аты_жөні	Студенттің толық аты-жөні	str (мәтін)	Нұрсұлтан Қалиев, Рамазан Нұрланов...
3	Факультет	Университеттегі факультет атауы (5 факультет)	str (санаттық)	Ақпараттық технологиялар, Экономика және бизнес, Инженерия...
4	Мамандық	Білім беру бағдарламасы (8 мамандық)	str (санаттық)	Информатика, Бағдарламалық инженерия, Ақпараттық қауіпсіздік...
5	Курс	Студенттің оқу курсы	int64 (сандық)	1, 2, 3, 4 курс
6	Қала	Студенттің келген қаласы (6 қала)	str (санаттық)	Алматы, Астана, Шымкент, Қызылорда, Ақтөбе, Қарағанды
7	Оқу_түрі	Білім алу негізі (грант немесе ақылы)	str (санаттық)	Грант, Ақылы
8	Қатысу_пайызы	Сабаққа қатысу үлесі (%)	int64 (сандық)	58% – 100% (орташа: 83.59%)
9	Аралық_бақылау	Аралық бақылау балы (РК1 + РК2, 100 балдық)	int64 (сандық)	56 – 100 балл (орташа: 77.72)
10	Емтихан_балы	Қорытынды емтихан балы (100 балдық)	int64 (сандық)	56 – 100 балл (орташа: 79.45)
11	GPA	Орташа академиялық үлгерім балы (0.0 – 4.0)	float64 (сандық)	1.99 – 3.96 (орташа: 2.98)
12	Стипендия	Ай сайынғы шәкіртақы мөлшері (теңге)	int64 (сандық)	0, 41898, 48183 тг (орташа: 19388.31 тг)

1-бөлім. Деректерді бастапқы зерттеу (1–5 тапсырмалар)

1. Өзіңіздің CSV файлыңызды жүктеп, алғашқы 10 жолын экранға шығарыңыз. `read_csv(), head()`

In [1]:
```
import pandas as pd

myData = pd.read_csv("students_data.csv")
print(myData.head(10))
```

Out[1]:

	Студент_ID	Аты_жөні	Факультет	Мамандық	Курс	Қала	Оқу_түрі	Қатысу_пайызы	Аралық_бақылау	Емтихан_балы	GPA	Стипендия
0	1	Нұрсұлтан Қалиев	Заң факультеті	Құқықтану	3	Шымкент	Грант	86	85	81	3.12	41898
1	2	Рамазан Нұрланов	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Алматы	Грант	79	74	77	2.78	41898
2	3	Көусар Тәжібаева	Заң факультеті	Құқықтану	2	Ақтөбе	Ақылы	81	76	78	2.96	0
3	4	Айша Мұратова	Ақпараттық технологиялар	Бағдарламалық инженерия	3	Астана	Грант	79	75	75	2.83	41898
4	5	Мәдина Төлегенова	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Шымкент	Грант	82	84	86	3.28	41898
5	6	Жансая Ахметова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	2	Қарағанды	Ақылы	86	89	89	3.48	0
6	7	Дария Тұрсынова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	1	Алматы	Грант	69	64	73	2.59	0
7	8	Бақтияр Омаров	Заң факультеті	Құқықтану	3	Ақтөбе	Ақылы	75	72	82	2.85	0
8	9	Санжар Қасымов	Экономика және бизнес	Менеджмент	4	Астана	Грант	92	88	96	3.68	41898
9	10	Нұрсұлтан Мұратов	Инженерия	Электр энергетикасы	1	Астана	Грант	83	83	93	3.52	41898

Түсіндірме:
Бұл тапсырмада екі негізгі әдіс қолданылды:
• read_csv('students_data.csv') — университет студенттерінің үлгерімі жазылған CSV файлды оқып, Pandas кітапханасының DataFrame (кестелік) құрылымына жүктейді.
• head(10) — жүктелген кестенің ең алғашқы 10 жолын (0-ден 9-ға дейінгі индекстерді) экранға шығарады.
CSV бойынша талдау: Кестеде 12 баған бар екені көрінеді: Студент_ID, Аты_жөні, Факультет, Мамандық, Курс, Қала, Оқу_түрі (Грант/Ақылы), Қатысу_пайызы, Аралық_бақылау, Емтихан_балы, GPA және Стипендия.

2. Жолдар мен бағандардың санын анықтап, баған атауларын шығарыңыз. `shape, columns`

In [2]:
```
print("Кесте өлшемі (shape):", myData.shape)
print("Жолдар саны:", myData.shape[0])
print("Бағандар саны:", myData.shape[1])
print("Баған атаулары:", myData.columns.tolist())
```

```
Кесте өлшемі (shape): (600, 12)
Жолдар саны: 600
Бағандар саны: 12
Баған атаулары: ['Студент_ID', 'Аты_жөні', 'Факультет', 'Мамандық', 'Курс', 'Қала', 'Оқу_түрі', 'Қатысу_пайызы', 'Аралық_бақылау',
'Емтихан_балы', 'GPA', 'Стипендия']
```

Түсіндірме:
Бұл тапсырмада кестенің құрылымын анықтайтын екі атрибут қолданылды:
• shape — DataFrame өлшемін (жолдар_саны, бағандар_саны) кортежі ретінде қайтарады. Біздің студенттер деректер жиыны 600 жолдан (студенттен) және 12 бағаннан тұрады.
• columns — кестедегі барлық 12 бағанның атауларын қайтарады, ал tolist() әдісі оларды Python тізімі ретінде шығарады.

3. Деректер типтерін және әр бағандағы бос емес мәндердің санын анықтаңыз. `info(), count()`

In [3]:
```
myData.info()
print("\nӘр бағандағы бос емес мәндер саны:")
print(myData.count())
```

```
<class 'pandas.DataFrame'>
RangeIndex: 600 entries, 0 to 599
Data columns (total 12 columns):
 #   Column          Non-Null Count  Dtype     | count()
---  ------          --------------  -----     | -------
 0   Студент_ID      600 non-null    int64     | 600
 1   Аты_жөні        600 non-null    str       | 600
 2   Факультет       600 non-null    str       | 600
 3   Мамандық        600 non-null    str       | 600
 4   Курс            600 non-null    int64     | 600
 5   Қала            600 non-null    str       | 600
 6   Оқу_түрі        600 non-null    str       | 600
 7   Қатысу_пайызы   600 non-null    int64     | 600
 8   Аралық_бақылау  600 non-null    int64     | 600
 9   Емтихан_балы    600 non-null    int64     | 600
 10  GPA             600 non-null    float64   | 600
 11  Стипендия       600 non-null    int64     | 600
dtypes: float64(1), int64(6), str(5)
```

Түсіндірме:
• info() әдісі кесте туралы толық техникалық мәлімет береді: жазбалар саны (600), бағандар тізімі, бос емес мәндер саны (Non-Null Count) және деректер типі (Dtype).
• count() әдісі әр бағандағы бос емес (NaN емес) мәндер санын жеке есептейді.
CSV бойынша талдау: Барлық 12 бағанда да 600 бос емес мән бар. 6 баған (Студент_ID, Курс, Қатысу_пайызы, Аралық_бақылау, Емтихан_балы, Стипендия) бүтін сандық int64 типінде, 1 баған (GPA) нақты сандық float64 типінде, ал 5 баған (Аты_жөні, Факультет, Мамандық, Қала, Оқу_түрі) мәтіндік (str) типінде сақталған.

4. Сандық бағандардың негізгі статистикалық сипаттамаларын алыңыз. `describe()`

In [4]:
```
print(myData.describe().round(2))
```

Out[4]:

	Көрсеткіш	Студент_ID	Курс	Қатысу_пайызы	Аралық_бақылау	Емтихан_балы	GPA	Стипендия
0	count	600	600	600	600	600	600	600
1	mean	300.50	2.24	83.59	77.72	79.45	2.98	19388.30
2	std	173.35	1.06	8.45	8.27	8.44	0.38	21040.78
3	min	1	1	58	56	56	1.99	0
4	25%	150.75	1	78	72	74	2.73	0
5	50%	300.50	2	83	78	79	2.98	0
6	75%	450.25	3	90	84	85	3.23	41898
7	max	600	4	100	100	100	3.96	48183

Түсіндірме:
• describe() әдісі кестедегі барлық сандық бағандар бойынша негізгі статистикалық көрсеткіштерді (саны — count, орташа мән — mean, стандартты ауытқу — std, минимум — min, 25%, 50% медиана, 75% квартильдер және максимум — max) автоматты түрде есептейді.
CSV бойынша талдау: Студенттердің орташа сабаққа қатысуы — 83.59% (58%-дан 100%-ға дейін), аралық бақылаудың орташа балы — 77.72, емтиханның орташа балы — 79.45 (56-ден 100-ге дейін), ал орташа GPA — 2.98 (1.99-ден 3.96-ға дейін).

5. Әр бағандағы бірегей мәндердің санын анықтаңыз. `nunique(), unique()`

In [5]:
```
print("Әр бағандағы бірегей мәндер саны:")
print(myData.nunique())
print("\nФакультеттер:", myData["Факультет"].unique())
print("Мамандықтар:", myData["Мамандық"].unique())
print("Қалалар:", myData["Қала"].unique())
print("Оқу түрі:", myData["Оқу_түрі"].unique())
```

```
Әр бағандағы бірегей мәндер саны:
Студент_ID        600
Аты_жөні          416
Факультет           5
Мамандық            8
Курс                4
Қала                6
Оқу_түрі            2
Қатысу_пайызы      41
Аралық_бақылау     44
Емтихан_балы       44
GPA               159
Стипендия           3

Факультеттер: ['Ақпараттық технологиялар' 'Экономика және бизнес' 'Инженерия' 'Педагогика' 'Заң факультеті']
Мамандықтар: ['Информатика' 'Бағдарламалық инженерия' 'Ақпараттық қауіпсіздік' 'Қаржы' 'Менеджмент' 'Электр энергетикасы' 'Математика'
'Құқықтану']
Қалалар: ['Алматы' 'Астана' 'Шымкент' 'Қызылорда' 'Ақтөбе' 'Қарағанды']
Оқу түрі: ['Грант' 'Ақылы']
```

Түсіндірме:
• nunique() әдісі әр бағанда қанша қайталанбайтын (бірегей) мән бар екенін санайды.
• unique() әдісі таңдалған санаттық бағанның нақты қандай бірегей мәндерден тұратынын массив ретінде шығарады.
CSV бойынша талдау: Университет деректерінде 5 факультет, 8 мамандық, 4 курс (1–4), 6 қала, 2 оқу түрі (Грант, Ақылы) және 3 шәкіртақы деңгейі (0, 41898, 48183 тг) бар.

2-бөлім. Деректерді тазалау және алдын ала өңдеу (6–10 тапсырмалар)

6. Бос мәндерді тауып, әр бағандағы олардың санын есептеңіз. `isnull(), sum()`

In [6]:
```
print("Әр бағандағы бос (NaN) мәндер саны:")
print(myData.isnull().sum())
print("Жалпы бос мәндер саны:", myData.isnull().sum().sum())
```

```
Әр бағандағы бос (NaN) мәндер саны:
Студент_ID        0
Аты_жөні          0
Факультет         0
Мамандық          0
Курс              0
Қала              0
Оқу_түрі          0
Қатысу_пайызы     0
Аралық_бақылау    0
Емтихан_балы      0
GPA               0
Стипендия         0
dtype: int64
Жалпы бос мәндер саны: 0
```

Түсіндірме:
• isnull() әдісі кестедегі әрбір ұяшықты тексеріп, егер мән бос (NaN) болса True, ал толық болса False қайтарады.
• sum() әдісі сол True (1-ге тең) мәндерін бағандар бойынша қосып, әр бағанда неше бос ұяшық бар екенін шығарады.
CSV бойынша талдау: Біздің students_data.csv файлында барлық 12 баған бойынша бос мәндер саны 0-ге тең, яғни деректер толық әрі таза.

7. Бос мәндерді жою немесе тиісті әдіспен толтыру. `dropna(), fillna()`

In [7]:
```
clean_drop = myData.dropna()
clean_fill = myData.copy()
clean_fill["GPA"] = clean_fill["GPA"].fillna(clean_fill["GPA"].mean())
clean_fill["Факультет"] = clean_fill["Факультет"].fillna("Белгісіз")
print("dropna() кейінгі кесте өлшемі:", clean_drop.shape)
print("fillna() кейінгі бос мәндер саны:", clean_fill.isnull().sum().sum())
```

```
dropna() кейінгі кесте өлшемі: (600, 12)
fillna() кейінгі бос мәндер саны: 0
```

Түсіндірме:
• dropna() — кемінде бір ұяшығы бос (NaN) болған жолдарды кестеден толықтай өшіреді.
• fillna() — бос ұяшықтарды өшірмей, оларды белгілі бір мәнмен (мысалы, сандық 'GPA' бағанын орташа мәнмен, ал мәтіндік 'Факультет' бағанын 'Белгісіз' сөзімен) толтырады.
CSV бойынша талдау: Бастапқы деректерде бос ұяшықтар болмағандықтан, dropna() әдісінен кейін де барлық 600 жол мен 12 баған өзгеріссіз сақталды.

8. Қайталанатын жолдарды анықтап, оларды жойыңыз. `duplicated(), drop_duplicates()`

In [8]:
```
dup_count = myData.duplicated().sum()
print("Қайталанатын (дубликат) жолдар саны:", dup_count)
myData_no_dup = myData.drop_duplicates()
print("Дубликаттарды жойғаннан кейінгі өлшем:", myData_no_dup.shape)
```

```
Қайталанатын (дубликат) жолдар саны: 0
Дубликаттарды жойғаннан кейінгі өлшем: (600, 12)
```

Түсіндірме:
• duplicated() — кестедегі жолдардың бұрынғы жолдармен толықтай қайталанатынын (дубликат екенін) тексереді, ал sum() олардың жалпы санын есептейді.
• drop_duplicates() — қайталанатын артық жолдарды өшіріп, тек бірегей жазбаларды қалдырады.
CSV бойынша талдау: Кестедегі әрбір студент жазбасы бірегей болғандықтан, қайталанатын жолдар саны 0 болды.

9. Бір немесе бірнеше бағанның деректер типін өзгертіңіз. `astype(), to_numeric()`

In [9]:
```
myData_types = myData.copy()
myData_types["Емтихан_балы"] = myData_types["Емтихан_балы"].astype(float)
myData_types["GPA"] = pd.to_numeric(myData_types["GPA"], errors="coerce")
print("Өзгертілген деректер типтері:")
print(myData_types[["Емтихан_балы", "GPA", "Курс"]].dtypes)
```

```
Өзгертілген деректер типтері:
Емтихан_балы    float64
GPA             float64
Курс              int64
dtype: object
```

Түсіндірме:
• astype(float) — 'Емтихан_балы' бағанының деректер типін бүтін саннан (int64) нақты бөлшек санға (float64) түрлендіреді.
• pd.to_numeric(..., errors='coerce') — баған мәндерін сандық типке ауыстырады (егер мәтіндік қате мәндер кездессе, оларды автоматты түрде NaN етеді).
CSV бойынша талдау: 'Емтихан_балы' бағаны int64 типінен float64 типіне сәтті ауыстырылды.

10. Бағандардың атауларын өзгерту және қажетсіз бағандарды жою. `rename(), drop()`

In [10]:
```
myData_renamed = myData.rename(columns={"Оқу_түрі": "Оқу_негізі"})
myData_dropped = myData_renamed.drop(columns=["Студент_ID"])
print("Жаңартылған бағандар саны:", myData_dropped.shape[1])
print("Жаңартылған баған атаулары:", myData_dropped.columns.tolist())
print(myData_dropped.head(5))
```

```
Жаңартылған бағандар саны: 11
Жаңартылған баған атаулары: ['Аты_жөні', 'Факультет', 'Мамандық', 'Курс', 'Қала', 'Оқу_негізі', 'Қатысу_пайызы', 'Аралық_бақылау',
'Емтихан_балы', 'GPA', 'Стипендия']
```

Out[10]:

	Аты_жөні	Факультет	Мамандық	Курс	Қала	Оқу_негізі	Қатысу_пайызы	Аралық_бақылау	Емтихан_балы	GPA	Стипендия
0	Нұрсұлтан Қалиев	Заң факультеті	Құқықтану	3	Шымкент	Грант	86	85	81	3.12	41898
1	Рамазан Нұрланов	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Алматы	Грант	79	74	77	2.78	41898
2	Қәусар Тәжібаева	Заң факультеті	Құқықтану	2	Ақтөбе	Ақылы	81	76	78	2.96	0
3	Айша Мұратова	Ақпараттық технологиялар	Бағдарламалық инженерия	3	Астана	Грант	79	75	75	2.83	41898
4	Мәдина Төлегенова	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Шымкент	Грант	82	84	86	3.28	41898

Түсіндірме:
• rename(columns={'Оқу_түрі': 'Оқу_негізі'}) — бағанның атауын жаңа атауға ('Оқу_негізі') өзгертеді.
• drop(columns=['Студент_ID']) — талдауға қажет емес реттік 'Студент_ID' бағанын кестеден өшіреді.
CSV бойынша талдау: 'Студент_ID' бағаны жойылғаннан кейін кестеде 12 бағанның орнына 11 мазмұндық баған қалды.

3-бөлім. Деректерді сүзгілеу және сұрыптау (11–15 тапсырмалар)

11. Сандық көрсеткіші (мысалы, GPA) орташа мәннен жоғары жолдарды таңдаңыз. `Шарттар, mean()`

In [11]:
```
mean_gpa = myData["GPA"].mean()
above_avg = myData[myData["GPA"] > mean_gpa]
print(f"Орташа GPA: {mean_gpa:.2f}")
print(f"GPA көрсеткіші орташадан жоғары студенттер саны: {len(above_avg)} (600 ішінен)")
print(above_avg.head(10))
```

```
Орташа GPA: 2.98
GPA көрсеткіші орташадан жоғары студенттер саны: 304 (600 ішінен)
```

Out[11]:

	Студент_ID	Аты_жөні	Факультет	Мамандық	Курс	Қала	Оқу_түрі	Қатысу_пайызы	Аралық_бақылау	Емтихан_балы	GPA	Стипендия
0	1	Нұрсұлтан Қалиев	Заң факультеті	Құқықтану	3	Шымкент	Грант	86	85	81	3.12	41898
4	5	Мәдина Төлегенова	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Шымкент	Грант	82	84	86	3.28	41898
5	6	Жансая Ахметова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	2	Қарағанды	Ақылы	86	89	89	3.48	0
8	9	Санжар Қасымов	Экономика және бизнес	Менеджмент	4	Астана	Грант	92	88	96	3.68	41898
9	10	Нұрсұлтан Мұратов	Инженерия	Электр энергетикасы	1	Астана	Грант	83	83	93	3.52	41898
10	11	Санжар Тәжібаев	Инженерия	Электр энергетикасы	2	Алматы	Ақылы	98	92	93	3.72	0
11	12	Томирис Оспанова	Педагогика	Математика	3	Алматы	Ақылы	96	87	86	3.40	0
12	13	Әлихан Нұрланов	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Астана	Грант	85	71	88	3.09	41898
14	15	Мирас Мұқанов	Ақпараттық технологиялар	Информатика	4	Астана	Грант	95	77	84	3.26	41898
15	16	Айша Әбдірахманова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	3	Алматы	Ақылы	96	77	86	3.33	0

Түсіндірме:
• myData['GPA'].mean() — барлық 600 студенттің орташа GPA көрсеткішін есептейді (нәтижесі: 2.98).
• myData[myData['GPA'] > mean_gpa] — логикалық шарт арқылы тек GPA балы 2.98-ден жоғары студенттерді сүзіп алады.
CSV бойынша талдау: Барлығы 600 студенттің ішінен 304 студенттің (50.7%) үлгерім балы университет бойынша орташа деңгейден жоғары.

12. Екі немесе одан да көп шартқа сәйкес келетін жазбаларды іріктеңіз. `loc[], логикалық операторлар (&, |)`

In [12]:
```
# 1) & (ЖӘНЕ) операторы: Ақпараттық технологиялар факультеті + Грант + GPA > 3.2
filter_and = myData.loc[
    (myData["Факультет"] == "Ақпараттық технологиялар") &
    (myData["Оқу_түрі"] == "Грант") &
    (myData["GPA"] > 3.2)
]
print("1) АТ факультетінде грантта оқитын және GPA > 3.2 студенттер саны:", len(filter_and))

# 2) | (НЕМЕСЕ) операторы: Алматы НЕМЕСЕ Астана қаласынан келген студенттер
filter_or = myData.loc[(myData["Қала"] == "Алматы") | (myData["Қала"] == "Астана")]
print("2) Алматы немесе Астана қаласынан келген студенттер саны:", len(filter_or))
print(filter_and.head(8))
```

```
1) АТ факультетінде грантта оқитын және GPA > 3.2 студенттер саны: 36
2) Алматы немесе Астана қаласынан келген студенттер саны: 291
```

Out[12]:

	Студент_ID	Аты_жөні	Факультет	Мамандық	Курс	Қала	Оқу_түрі	Қатысу_пайызы	Аралық_бақылау	Емтихан_балы	GPA	Стипендия
4	5	Мәдина Төлегенова	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Шымкент	Грант	82	84	86	3.28	41898
14	15	Мирас Мұқанов	Ақпараттық технологиялар	Информатика	4	Астана	Грант	95	77	84	3.26	41898
31	32	Ілияс Тәжібаев	Ақпараттық технологиялар	Бағдарламалық инженерия	2	Қызылорда	Грант	81	87	84	3.21	41898
57	58	Нұрай Ибраева	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	2	Қызылорда	Грант	91	85	83	3.29	41898
81	82	Ілияс Сүлейменов	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	2	Ақтөбе	Грант	91	86	86	3.33	41898
92	93	Көусар Кенжебаева	Ақпараттық технологиялар	Бағдарламалық инженерия	3	Шымкент	Грант	95	89	94	3.73	41898
111	112	Айша Мұқанова	Ақпараттық технологиялар	Бағдарламалық инженерия	4	Шымкент	Грант	93	94	87	3.50	41898
112	113	Әлихан Әбдірахманов	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	1	Алматы	Грант	90	82	91	3.40	41898

Түсіндірме:
• loc[] — жолдар мен бағандарды белгіленген логикалық шарттар бойынша іріктеп алу индексаторы.
• & (ЖӘНЕ) операторы барлық шарттардың бір мезгілде орындалуын талап етеді, ал | (НЕМЕСЕ) операторы кемінде бір шарттың орындалуын тексереді.
CSV бойынша талдау: Ақпараттық технологиялар факультетінде грантта оқитын әрі GPA балы 3.2-ден асатын 36 үздік студент табылды. Ал Алматы немесе Астана қалаларынан келген студенттер саны — 291.

---

13. Таңдалған көрсеткіш бойынша ең үлкен мәндері бар 10 жазбаны табыңыз. `nlargest()`

In [13]:
```
top10_exam = myData.nlargest(10, "Емтихан_балы")
print(top10_exam[["Студент_ID", "Аты_жөні", "Факультет", "Мамандық", "Курс", "Қала", "Емтихан_балы", "GPA", "Стипендия"]])
```

Out[13]:

	Студент_ID	Аты_жөні	Факультет	Мамандық	Курс	Қала	Емтихан_балы	GPA	Стипендия
67	68	Темірлан Құдайбергенов	Экономика және бизнес	Менеджмент	2	Қызылорда	100	3.78	0
210	211	Көусар Болатова	Педагогика	Математика	3	Ақтөбе	100	3.96	48183
234	235	Мирас Нұрланов	Педагогика	Математика	1	Ақтөбе	100	3.79	48183
345	346	Көусар Нұрланова	Педагогика	Математика	4	Алматы	100	3.92	0
365	366	Бекзат Мұратов	Ақпараттық технологиялар	Бағдарламалық инженерия	4	Қарағанды	100	3.84	0
265	266	Бақтияр Қасымов	Педагогика	Математика	1	Ақтөбе	99	3.56	41898
32	33	Нұрсұлтан Төлегенов	Ақпараттық технологиялар	Бағдарламалық инженерия	3	Алматы	98	3.55	0
137	138	Бекзат Нұрланов	Ақпараттық технологиялар	Бағдарламалық инженерия	3	Астана	98	3.71	0
297	298	Мирас Құдайбергенов	Заң факультеті	Құқықтану	3	Қызылорда	98	3.48	0
424	425	Әлихан Төлегенов	Ақпараттық технологиялар	Информатика	4	Шымкент	98	3.68	0

Түсіндірме:
• nlargest(10, 'Емтихан_балы') — деректерді толық сұрыптамай-ақ, 'Емтихан_балы' бағаны бойынша ең жоғары 10 жазбаны кему ретімен жылдам таңдап береді.
CSV бойынша талдау: Емтиханнан ең жоғары балл (100 балл) жинаған ТОП-10 студенттің тізімі шығарылды. Олардың GPA көрсеткіштері де өте жоғары (3.55 – 4.00 аралығында).

14. Ең кіші мәндері бар 5 жазбаны табыңыз. `nsmallest()`

In [14]:
```
bottom5_gpa = myData.nsmallest(5, "GPA")
print(bottom5_gpa[["Студент_ID", "Аты_жөні", "Факультет", "Мамандық", "Курс", "Қала", "Қатысу_пайызы", "Емтихан_балы", "GPA"]])
```

Out[14]:

	Студент_ID	Аты_жөні	Факультет	Мамандық	Курс	Қала	Қатысу_пайызы	Емтихан_балы	GPA
334	335	Аяулым Мұқанова	Инженерия	Электр энергетикасы	1	Астана	67	60	1.99
300	301	Мадияр Кенжебаев	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	2	Алматы	63	58	2.10
331	332	Ілияс Байжанов	Экономика және бизнес	Менеджмент	1	Алматы	68	58	2.10
400	401	Ілияс Байжанов	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Шымкент	65	60	2.10
49	50	Аяулым Мұратова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	1	Алматы	58	59	2.12

Түсіндірме:
• nsmallest(5, 'GPA') — 'GPA' бағаны бойынша ең төменгі 5 жазбаны өсу ретімен табады.
CSV бойынша талдау: Ең төменгі GPA көрсеткіші — 1.99 балл (Аяулым Мұқанова, Инженерия). Кестеден бұл студенттердің сабаққа қатысу пайызы да төмен (58%–68%) екенін байқауға болады.

15. Деректерді бір немесе бірнеше баған бойынша сұрыптаңыз. `sort_values()`

In [15]:
```
sorted_data = myData.sort_values(by=["Факультет", "GPA"], ascending=[True, False])
print(sorted_data[["Студент_ID", "Аты_жөні", "Факультет", "Мамандық", "Курс", "Емтихан_балы", "GPA", "Стипендия"]].head(10))
```

Out[15]:

	Студент_ID	Аты_жөні	Факультет	Мамандық	Курс	Емтихан_балы	GPA	Стипендия
255	256	Темірлан Ахметов	Ақпараттық технологиялар	Бағдарламалық инженерия	3	97	3.90	48183
340	341	Ілияс Омаров	Ақпараттық технологиялар	Информатика	1	96	3.84	48183
365	366	Бекзат Мұратов	Ақпараттық технологиялар	Бағдарламалық инженерия	4	100	3.84	0
189	190	Қаусар Мұратова	Ақпараттық технологиялар	Информатика	1	93	3.81	0
120	121	Мадияр Ермеков	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	1	96	3.79	48183
528	529	Жансая Әбдірахманова	Ақпараттық технологиялар	Информатика	2	97	3.76	48183
92	93	Қаусар Кенжебаева	Ақпараттық технологиялар	Бағдарламалық инженерия	3	94	3.73	41898
137	138	Бекзат Нұрланов	Ақпараттық технологиялар	Бағдарламалық инженерия	3	98	3.71	0
326	327	Мәдина Ермекова	Ақпараттық технологиялар	Бағдарламалық инженерия	3	94	3.71	48183
424	425	Әлихан Төлегенов	Ақпараттық технологиялар	Информатика	4	98	3.68	0

Түсіндірме:
• sort_values(by=['Факультет', 'GPA'], ascending=[True, False]) — кестені бірнеше бағаны бойынша сұрыптайды: алдымен 'Факультет' атауын әліпби ретімен (ascending=True: Ақпараттық технологиялар бірінші), ал әр факультет ішінде 'GPA' балын кему ретімен (ascending=False: ең үздігінен бастап) реттейді.
CSV бойынша талдау: Нәтижеде Ақпараттық технологиялар факультетінің ең үздік студенттері тізім басына шықты (ең жоғары GPA = 3.90).

4-бөлім. Статистикалық талдау (16–20 тапсырмалар)

16. Сандық көрсеткіштердің орташа мәнін, медианасын, минимумын және максимумын есептеңіз. `mean()`, `median()`, `min()`, `max()`

In [16]:
```
num_cols = ["Курс", "Қатысу_пайызы", "Аралық_бақылау", "Емтихан_балы", "GPA", "Стипендия"]
stats_16 = pd.DataFrame({
    "Орташа мән (mean)": myData[num_cols].mean().round(2),
    "Медиана (median)": myData[num_cols].median().round(2),
    "Минимум (min)": myData[num_cols].min(),
    "Максимум (max)": myData[num_cols].max()
})
print(stats_16)
```

Out[16]:

	Көрсеткіш (Баған)	Орташа мән (mean)	Медиана (median)	Минимум (min)	Максимум (max)
0	Курс	2.24	2	1	4
1	Қатысу_пайызы	83.59	83	58	100
2	Аралық_бақылау	77.72	78	56	100
3	Емтихан_балы	79.45	79	56	100
4	GPA	2.98	2.98	1.99	3.96
5	Стипендия	19388.30	0	0	48183

Түсіндірме:
• mean() — арифметикалық орташа мәнді, median() — реттелген қатардың дәл ортасындағы медианаңы, min() — ең кіші мәнді, max() — ең үлкен мәнді есептейді.
CSV бойынша талдау: Барлық сандық бағандарда орташа мән мен медиана бір-біріне өте жақын (мысалы, GPA орташасы — 2.98, медианасы — 2.98; Емтихан балының орташасы — 79.45, медианасы — 79.00). Бұл студенттер үлгерімінің қалыпты (симметриялы) таралғанын дәлелдейді.

17. Стандартты ауытқу мен дисперсияны есептеңіз. `std(), var()`

In [17]:
```
stats_17 = pd.DataFrame({
    "Стандартты ауытқу (std)": myData[num_cols].std().round(2),
    "Дисперсия (var)": myData[num_cols].var().round(2)
})
print(stats_17)
```

Out[17]:

	Көрсеткіш (Баған)	Стандартты ауытқу (std)	Дисперсия (var)
0	Курс	1.06	1.13
1	Қатысу_пайызы	8.45	71.47
2	Аралық_бақылау	8.27	68.47
3	Емтихан_балы	8.44	71.27
4	GPA	0.38	0.14
5	Стипендия	21040.78	442714575.92

Түсіндірме:
• std() (стандартты ауытқу) және var() (дисперсия, яғни std квадраты) — деректердің орташа мәннен қаншалықты алшақ шашырағанын көрсетеді.
CSV бойынша талдау: GPA бойынша стандартты ауытқу небәрі 0.38 балды құрайды (дисперсиясы 0.14), ал Емтихан балы бойынша std = 8.44 балл.

---

18. Таңдалған көрсеткіштің 25, 50 және 75-процентильдерін табыңыз. `quantile()`

In [18]:
```
q_table = myData[["GPA", "Емтихан_балы", "Қатысу_пайызы"]].quantile([0.25, 0.50, 0.75])
print(q_table)
```

Out[18]:

	Процентиль	GPA	Емтихан_балы	Қатысу_пайызы
0	25% (0.25 квартиль)	2.73	74	78
1	50% (0.50 медиана)	2.98	79	83
2	75% (0.75 квартиль)	3.23	85	90

Түсіндірме:
• quantile([0.25, 0.50, 0.75]) — деректерді төрт тең бөлікке бөлетін квартильдік шектерді (25%, 50% медиана, 75%) есептейді.
CSV бойынша талдау: Студенттердің 25%-ында GPA 2.73-ден төмен, 50%-ында (медиана) 2.98-ден төмен, ал ең үздік 25% студенттің GPA көрсеткіші 3.23-ден жоғары (4.00-ге дейін).

---

19. Ең жиі кездесетін мәнді анықтаңыз. `mode(), value_counts()`

In [19]:
```
for col in ["Факультет", "Мамандық", "Қала", "Оқу_түрі"]:
    print(f"{col} модасы: {myData[col].mode()[0]}")
    print(myData[col].value_counts())
    print("-" * 40)
```

```
Факультет модасы: Ақпараттық технологиялар
  Ақпараттық технологиялар: 209
  Экономика және бизнес: 146
  Педагогика: 97
  Инженерия: 85
  Заң факультеті: 63

Мамандық модасы: Математика
  Математика: 97
  Электр энергетикасы: 85
  Қаржы: 75
  Информатика: 73
  Бағдарламалық инженерия: 71
  Менеджмент: 71
  Ақпараттық қауіпсіздік: 65
  Құқықтану: 63

Қала модасы: Алматы
  Алматы: 173
  Астана: 118
  Шымкент: 108
  Қызылорда: 92
  Ақтөбе: 70
  Қарағанды: 39

Оқу_түрі модасы: Грант
  Грант: 371
  Ақылы: 229
```

Түсіндірме:
• mode() — бағандағы ең жиі кездесетін мәнді (моданы) табады.
• value_counts() — бағандағы әрбір бірегей мәннің қанша рет кездесетінін кему ретімен санап береді.
CSV бойынша талдау: Ең көп студент оқитын факультет — 'Ақпараттық технологиялар' (209 студент), ең танымал мамандық — 'Математика' (97 студент), ең көп студент келген қала — 'Алматы' (173 студент), ал оқу түрі бойынша 'Грант' (371 студент) басым.

---

20. Екі немесе бірнеше сандық бағаң арасындағы корреляцияны зерттеңіз. `corr()`

In [20]:
```
corr_matrix = myData[num_cols].corr().round(3)
print(corr_matrix)
```

Out[20]:

	Бағандар	Курс	Қатысу_пайызы	Аралық_бақылау	Емтихан_балы	GPA	Стипендия
0	Курс	1.0	-0.005	0.025	0.027	0.036	0.004
1	Қатысу_пайызы	-0.005	1.0	0.694	0.644	0.711	0.325
2	Аралық_бақылау	0.025	0.694	1.0	0.671	0.855	0.427
3	Емтихан_балы	0.027	0.644	0.671	1.0	0.926	0.343
4	GPA	0.036	0.711	0.855	0.926	1.0	0.4
5	Стипендия	0.004	0.325	0.427	0.343	0.4	1.0

Түсіндірме:
• corr() — сандық бағандар арасындағы Пирсонның сызықтық корреляция коэффициенттерінің матрицасын (-1 мен +1 аралығында) есептейді.
CSV бойынша талдау: Кестеде өте күшті оң корреляция байқалады:
1) Сабаққа қатысу пайызы мен Аралық бақылау арасындағы байланыс r = 0.694, ал GPA-мен байланысы r = 0.711.
2) Емтихан балы мен GPA арасындағы корреляция r = 0.926 (өте тығыз байланыс).
3) GPA мен Стипендия мөлшері арасында да айқын оң корреляция бар (r = 0.400), яғни сабаққа тұрақты қатысып, жоғары балл жинаған студенттер жоғары GPA мен шәкіртақыға ие болады.

Қосымша: students_data.csv деректер кестесі (2 беттік үлгі — 1–76 жазбалар)

Төменде «students_data.csv» файлының барлық 12 бағанын қамтитын 2 беттік деректер кестесі берілген:

In [21]:
```
myData.head(76)
```

Out[21]:

	Студент_ID	Аты_жөні	Факультет	Мамандық	Курс	Қала	Оқу_түрі	Қатысу_пайызы	Аралық_бақылау	Емтихан_балы	GPA	Стипендия
0	1	Нұрсұлтан Қалиев	Заң факультеті	Құқықтану	3	Шымкент	Грант	86	85	81	3.12	41898
1	2	Рамазан Нұрланов	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Алматы	Грант	79	74	77	2.78	41898
2	3	Кәусар Тәжібаева	Заң факультеті	Құқықтану	2	Ақтөбе	Ақылы	81	76	78	2.96	0
3	4	Айша Мұратова	Ақпараттық технологиялар	Бағдарламалық инженерия	3	Астана	Грант	79	75	75	2.83	41898
4	5	Мәдина Төлегенова	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Шымкент	Грант	82	84	86	3.28	41898
5	6	Жансая Ахметова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	2	Қарағанды	Ақылы	86	89	89	3.48	0
6	7	Дария Тұрсынова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	1	Алматы	Грант	69	64	73	2.59	0
7	8	Бақтияр Омаров	Заң факультеті	Құқықтану	3	Ақтөбе	Ақылы	75	72	82	2.85	0
8	9	Санжар Қасымов	Экономика және бизнес	Менеджмент	4	Астана	Грант	92	88	96	3.68	41898
9	10	Нұрсұлтан Мұратов	Инженерия	Электр энергетикасы	1	Астана	Грант	83	83	93	3.52	41898
10	11	Санжар Тәжібаев	Инженерия	Электр энергетикасы	2	Алматы	Ақылы	98	92	93	3.72	0
11	12	Томирис Оспанова	Педагогика	Математика	3	Алматы	Ақылы	96	87	86	3.40	0
12	13	Әлихан Нұрланов	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Астана	Грант	85	71	88	3.09	41898
13	14	Айдана Ермекова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	2	Шымкент	Ақылы	86	79	69	2.70	0
14	15	Мирас Мұқанов	Ақпараттық технологиялар	Информатика	4	Астана	Грант	95	77	84	3.26	41898
15	16	Айша Әбдірахманова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	3	Алматы	Ақылы	96	77	86	3.33	0
16	17	Жансая Сейітова	Педагогика	Математика	2	Алматы	Грант	99	93	92	3.61	41898
17	18	Арсен Қалиев	Инженерия	Электр энергетикасы	1	Қызылорда	Грант	76	71	78	2.71	41898
18	19	Айша Сейітова	Экономика және бизнес	Менеджмент	1	Қарағанды	Ақылы	93	85	83	3.15	0
19	20	Арсен Сейітов	Педагогика	Математика	4	Астана	Ақылы	89	88	76	3.17	0
20	21	Алдияр Қасымов	Заң факультеті	Құқықтану	1	Астана	Грант	85	79	72	2.79	41898
21	22	Нұрай Сүлейменова	Педагогика	Математика	3	Шымкент	Грант	71	65	74	2.56	0
22	23	Бақтияр Серіков	Ақпараттық технологиялар	Информатика	2	Астана	Грант	75	78	77	2.90	41898
23	24	Мирас Ермеков	Заң факультеті	Құқықтану	4	Ақтөбе	Грант	88	80	77	2.83	41898
24	25	Мадияр Нұрланов	Ақпараттық технологиялар	Бағдарламалық инженерия	2	Қарағанды	Ақылы	76	74	75	2.69	0
25	26	Айзере Кенжебаева	Педагогика	Математика	1	Қызылорда	Грант	77	63	73	2.40	0
26	27	Дария Жұмабаева	Экономика және бизнес	Қаржы	1	Алматы	Грант	84	76	90	3.20	41898
27	28	Арсен Ибраев	Экономика және бизнес	Менеджмент	1	Алматы	Грант	66	69	66	2.49	0
28	29	Кәусар Омарова	Экономика және бизнес	Менеджмент	1	Шымкент	Грант	96	91	90	3.57	41898
29	30	Томирис Байжанова	Педагогика	Математика	1	Астана	Грант	88	86	78	3.07	41898
30	31	Әлихан Ахметов	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Алматы	Ақылы	86	93	84	3.56	0
31	32	Ілияс Тәжібаев	Ақпараттық технологиялар	Бағдарламалық инженерия	2	Қызылорда	Грант	81	87	84	3.21	41898
32	33	Нұрсұлтан Төлегенов	Ақпараттық технологиялар	Бағдарламалық инженерия	3	Алматы	Ақылы	81	79	98	3.55	0
33	34	Темірлан Төлегенов	Инженерия	Электр энергетикасы	4	Қарағанды	Ақылы	94	88	93	3.71	0
34	35	Әлихан Нұрланов	Педагогика	Математика	4	Шымкент	Ақылы	73	74	69	2.55	0
35	36	Аяулым Серікова	Ақпараттық технологиялар	Бағдарламалық инженерия	3	Алматы	Грант	78	79	80	2.97	41898
36	37	Темірлан Сағындықов	Педагогика	Математика	3	Қызылорда	Грант	88	76	69	2.55	0
37	38	Нұрсұлтан Мұқанов	Педагогика	Математика	2	Алматы	Ақылы	76	78	81	2.85	0
38	39	Дильназ Сейітова	Экономика және бизнес	Қаржы	4	Астана	Грант	86	79	81	3.10	41898
39	40	Данияр Сейітов	Экономика және бизнес	Қаржы	3	Шымкент	Грант	100	91	92	3.60	41898
40	41	Аружан Жұмабаева	Экономика және бизнес	Менеджмент	1	Ақтөбе	Ақылы	94	82	81	3.22	0
41	42	Арсен Ермеков	Экономика және бизнес	Қаржы	1	Астана	Грант	78	65	80	2.79	0
42	43	Мәдина Мұратова	Инженерия	Электр энергетикасы	3	Алматы	Грант	76	73	59	2.39	0
43	44	Айша Ермекова	Заң факультеті	Құқықтану	2	Астана	Грант	91	76	76	2.77	41898
44	45	Әлихан Оспанов	Инженерия	Электр энергетикасы	2	Қызылорда	Ақылы	76	71	67	2.45	0
45	46	Інжу Сүлейменова	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Астана	Грант	79	75	73	2.61	0
46	47	Темірлан Сейітов	Ақпараттық технологиялар	Бағдарламалық инженерия	1	Қарағанды	Грант	91	84	78	3.07	41898
47	48	Нұрай Нұрланова	Педагогика	Математика	2	Қарағанды	Грант	78	83	82	3.25	41898
48	49	Әлихан Серіков	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	1	Алматы	Ақылы	84	78	77	2.97	0
49	50	Аяулым Мұратова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	1	Алматы	Ақылы	58	60	59	2.12	0
50	51	Әлихан Ибраев	Заң факультеті	Құқықтану	1	Қызылорда	Грант	60	59	66	2.33	0
51	52	Бекзат Байжанов	Заң факультеті	Құқықтану	3	Қарағанды	Грант	91	95	93	3.67	48183
52	53	Алдияр Әбдірахманов	Экономика және бизнес	Қаржы	2	Шымкент	Ақылы	83	82	80	2.95	0
53	54	Айзере Әбдірахманова	Экономика және бизнес	Қаржы	1	Шымкент	Грант	64	77	62	2.58	0
54	55	Жансая Сүлейменова	Ақпараттық технологиялар	Информатика	4	Астана	Ақылы	79	72	70	2.55	0
55	56	Рамазан Әбдірахманов	Ақпараттық технологиялар	Информатика	2	Ақтөбе	Грант	73	64	68	2.32	0
56	57	Амина Ахметова	Экономика және бизнес	Қаржы	4	Алматы	Грант	89	86	82	3.17	41898
57	58	Нұрай Ибраева	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	2	Қызылорда	Грант	91	85	83	3.29	41898
58	59	Арсен Ахметов	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	2	Алматы	Грант	78	68	82	2.94	0
59	60	Ерасыл Мұратов	Экономика және бизнес	Қаржы	3	Қызылорда	Грант	97	98	85	3.44	41898
60	61	Дильназ Серікова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	4	Шымкент	Грант	78	71	70	2.51	0
61	62	Нұрай Тәжібаева	Педагогика	Математика	1	Алматы	Ақылы	91	84	96	3.57	0
62	63	Томирис Серікова	Экономика және бизнес	Менеджмент	2	Ақтөбе	Грант	89	76	91	3.30	41898

	Студент_ID	Аты_жөні	Факультет	Мамандық	Курс	Қала	Оқу_түрі	Қатысу_пайызы	Аралық_бақылау	Емтихан_балы	GPA	Стипендия
63	64	Аяулым Әбдірахманова	Экономика және бизнес	Қаржы	4	Астана	Грант	77	61	80	2.83	0
64	65	Айзере Тұрсынова	Инженерия	Электр энергетикасы	1	Алматы	Грант	83	71	83	2.99	41898
65	66	Мирас Омаров	Педагогика	Математика	4	Алматы	Ақылы	84	77	86	3.18	0
66	67	Мәдина Сағындықова	Педагогика	Математика	1	Алматы	Грант	88	87	73	3	41898
67	68	Темірлан Құдайбергенов	Экономика және бизнес	Менеджмент	2	Қызылорда	Ақылы	90	95	100	3.78	0
68	69	Мирас Нұрланов	Экономика және бизнес	Менеджмент	2	Ақтөбе	Ақылы	70	76	76	2.81	0
69	70	Ілияс Нұрланов	Экономика және бизнес	Қаржы	2	Қарағанды	Ақылы	92	88	85	3.30	0
70	71	Айзере Құдайбергенова	Экономика және бизнес	Менеджмент	2	Ақтөбе	Грант	95	83	83	3.14	41898
71	72	Кәусар Тұрсынова	Инженерия	Электр энергетикасы	3	Қызылорда	Грант	77	66	60	2.31	0
72	73	Данияр Болатов	Инженерия	Электр энергетикасы	4	Алматы	Грант	91	77	76	2.88	41898
73	74	Жансая Төлегенова	Педагогика	Математика	1	Шымкент	Ақылы	78	73	73	2.67	0
74	75	Айша Болатова	Ақпараттық технологиялар	Ақпараттық қауіпсіздік	4	Ақтөбе	Грант	68	77	73	2.75	41898
75	76	Дильназ Оспанова	Инженерия	Электр энергетикасы	1	Астана	Ақылы	83	82	87	3.28	0